


Метод главных компонент Principal Component Analysis, PCA

Суть метода.

Даны центрированные данные $X \in \mathbb{R}^{n \times d}$ ← кол-во признаков
Мы хотим заменить множество коррелированных признаков меньшим числом новых переменных — главных компонент — таких, чтобы:

- первая компонента улавливала максимально возможную дисперсию данных
- вторая — максимальную из оставшейся при ортогональности к первой, и так далее для последующих компонент.

Геометрически: ищем k -размерное подпространство с ортонорм. базисом, на которое ортопроекция X „теряет“ как можно меньше информации



Формальная постановка задачи. (и решение)

Пусть дана матрица данных $X \in \mathbb{R}^{n \times d}$ -
n наблюдений по d признакам. Предполагается
центрировка по столбцам: $\frac{1}{n} \sum_{i=1}^n x_{ij} = 0 \quad \forall j \in \{1, 2, \dots, d\}$

Хотим перейти к $Z \in \mathbb{R}^{n \times \ell}$, где $\ell < d$

Ищем главные компоненты $u_1, u_2, \dots, u_\ell \in \mathbb{R}^d$.

Требования: 1) $\|u_i\|^2 = 1$ 2) $\langle u_i, u_j \rangle = 0, i \neq j$

3) при проецировании X на u_1, u_2, \dots, u_ℓ получается
макс. дисперсия проекций среди всех способов выбрать

• Если X проецируем на u_i : $u_i (u_i^T u_i)^{-1} u_i^T X = u_i \langle u_i, X \rangle$

Был X $\xrightarrow[\ell \text{ компонент}]{\text{проецируем на 1-е}}$ $\begin{matrix} \langle u_1, X \rangle & u_1 \\ \langle u_2, X \rangle & u_2 \\ \vdots & \vdots \\ \langle u_\ell, X \rangle & u_\ell \end{matrix}$
ортонорм. базис

\Rightarrow Воспринимает X новый как
набор коэф-в $\langle u_1, X \rangle, \dots, \langle u_\ell, X \rangle$
новые признаки
(линейные комбинации исходных)

! $\langle u_1, X \rangle = \sum_{j=1}^d u_{1j} \cdot x_j$ - т.е. взвешенная сумма исходных признаков \hat{u}_1

Найдём сначала u_1 (попытки про макс. дисперсию)

$$\begin{cases} \|X u_1\|^2 \rightarrow \max u_1 \\ \|u_1\|^2 = 1 \end{cases}$$

$X u_1$ - вектор скалярных произведений

Выполним (узнаем?) метод множителей Лагранжа

$$L(x, \lambda) = f(x) + \lambda \cdot \varphi(x)$$

Вернёмся к нашей задаче

$$L(u_1, \lambda) = \|X u_1\|^2 + \lambda (\|u_1\|^2 - 1)$$

$$\nabla \|X u_1\|^2 = u_1^T X^T X u_1 \quad \|u_1\|^2 = u_1^T u_1$$

Теперь надо продифференцировать по u ,

Быстрый экскурс:

$$f(x_0+h) = f(x_0) + [D_{x_0} f](h) + o(\|h\|)$$

$$f(u_1) = \|Xu_1\|^2 = u_1^T X^T X u_1 = \langle Xu_1, Xu_1 \rangle$$

$$[D_{u_1} \langle Xu_1, Xu_1 \rangle](h) = \langle [D_{u_1} (Xu_1)](h), Xu_1 \rangle + \langle Xu_1, [D_{u_1} (Xu_1)](h) \rangle$$

$$= 2 \langle Xu_1, [D_{u_1} (Xu_1)](h) \rangle = 2 \langle Xu_1, Xh \rangle =$$

$$= 2 \langle X^T Xu_1, h \rangle \Rightarrow \nabla_{u_1} f = 2 X^T Xu_1$$

Аналогично с $f(u_1) = \|u_1\|^2$ $\nabla_{u_1} f = 2u_1$

$$\Rightarrow \nabla_{u_1} L = 2X^T Xu_1 + 2\lambda u_1 = 0 \quad \underbrace{X^T Xu_1 = -\lambda u_1}_{\downarrow} \quad -\lambda = \mu$$

$\Rightarrow u_1$ - собственный вектор $X^T X$

Вернёмся к формуле $\|Xu_1\|^2 = u_1^T X^T X u_1 = \mu u_1^T u_1 = \mu$
(т.е. мы максимизируем собствен. значение)

u_2 - второй собствен. вектор по 2-ому максимальному
собственному значению

\vdots

$$\Rightarrow \text{тогда} \quad Z = \overset{n \times d}{X} \cdot \overset{d \times l}{U}$$

u_2 так далее

$$f(x_0+h) = \|Xu_1 + Xh\|^2 = \langle Xu_1 + Xh, Xu_1 + Xh \rangle$$

$$\|Xu_1\|^2 = f(x_0)$$

$$\|Xh\|^2 = o(h)$$

$$u_1^T X^T Xu_1 + \underbrace{u_1^T X^T Xh + h^T X^T Xu_1}_{2 \langle X^T Xu_1, h \rangle} + h^T X^T Xh$$

Считаем
по определению
(в лоб)

Связь с SVD

Мат. содержание метода глав. компонент - спектральное разложение коварианц. матрицы C ($C = X^T X$, но мы не знаем (вроде?) что это, поэтому устно немного инфы), то есть представление прост-ва данных в виде суммы взаимно орт. собств. подпростр. C

$$C = X^T X = Q \cdot \Lambda \cdot Q^{-1}$$

Λ - диагональная матрица собств. значений

Q - матрицы, столбцы собств. вектора

! $X^T X$ - симм. + веществ. $\Rightarrow C = Q \cdot \Lambda \cdot Q^T$

$$X = U \Sigma V^T$$

$$X^T X = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

$$\Lambda = \Sigma^T \Sigma \quad (\lambda_i = \sigma_i^2)$$

Как выбирать число компонент?

- Кумулятивная доля объяснённой дисперсии - выбираем мин. k , где $\sum_{i=1}^k \lambda_i : \sum_{i=1}^d \lambda_i \geq \tau$
(τ - процент, который хотим сохранить, например 0,9)

- Метод „сломанной трости“ (scree plot) - строим график собственных значений и их дол. Ищем „излом“ - точку, где значения резко уменьшаются. Математически.

C - выборочная ковариационная матрица

λ_i - собственное значение

ℓ_i - ожидаемая доля дисперсии для j -й компоненты „случайных“ данных без структуры

$$\ell_i = \frac{1}{d} \cdot \sum_{j=1}^d \frac{1}{j} \quad (\text{пример } \ell_3 = \frac{1}{6} \cdot (\frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \frac{1}{6}))$$

Сохраняем вектор, если $\frac{\lambda_i}{\text{tr } C} > \ell_i$ (и все до i тоже)


- Правило Кайзера - знаем главные компоненты, для которых $\lambda_i > \frac{1}{d} \cdot \text{tr } C$
(хорошо работает на простых случаях)

- По числу обусловленности. Выбираем $\kappa_0 > 1$ и оставляем компоненты, для которых $\lambda_i > \frac{\lambda_1}{\kappa_0}$

Примеры применения.

- Сжатие изображений
- Визуализация (при снижении размерности до 2-3)
- Финансы (факторы доходностей)

- Подавление шума на изображениях
- Биоинформатика



PCA
Reconstruction
→



Original Image Data
Image size (kB): 465.8779296875
Image Shape: (1024, 1024, 3)

Compressed Image Data
Image size (kB): 86.8994140625
Percentage: 81.34 %
Image Shape: (1024, 1024, 3)