

Spectral Clustering

На основе статьи "A Tutorial on Spectral Clustering", Ulrike von Luxburg, 2007

Загонов Дмитрий

Национальный исследовательский университет
"Высшая школа экономики"

15 декабря 2025 г.

Метод k-средних (k-means)

Задача. Даны точки $x_1, \dots, x_n \in \mathbb{R}^d$. Требуется разбить их на k кластеров.

Оптимизационная постановка.

$$\min_{C_1, \dots, C_k} \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2, \quad \mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$



Алгоритм (Лloyd).

- Инициализировать центры μ_1, \dots, μ_k
- *Assignment*: каждая точка \rightarrow ближайший центр
- *Update*: μ_i — среднее точек кластера
- Повторять до сходимости

Геометрическая интерпретация.

- Кластеры — выпуклые области
- Границы — линейные (ячейки Вороного)
- Главный минус: не может распознавать кластеры сложной формы.

Демонстрация работы k-means



Мотивация спектральной кластеризации

Проблема k-means.

- Использует только координаты точек в \mathbb{R}^d
- Кластеры должны быть выпуклыми
- Плохо работает для сложной геометрии данных

Ключевая идея.

- Важны не координаты, а *связи* между точками
- Опишем данные как граф сходства

Граф сходства.

- Вершины — точки данных
- Рёбра — мера близости (например, $k\text{NN}$ или Gaussian kernel)

Интуиция кластеризации.

- Внутри кластера — сильные связи
- Между кластерами — слабые связи

Построение графа связности

Исходные данные. Даны точки x_1, \dots, x_n и функция сходства $s(x_i, x_j)$. Пример функции сходства - гауссовское ядро: $s(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$.

Способы построения графа.

- ε -граф:

$$w_{ij} = \begin{cases} s(x_i, x_j), & \|x_i - x_j\| \leq \varepsilon \\ 0, & \text{иначе} \end{cases}$$

- k ближайших соседей (k NN-граф):
 - соединяем x_i с его k ближайшими соседями
 - граф может быть ориентированным или симметризованным
- Полносвязный граф:

$$w_{ij} = s(x_i, x_j) \quad \text{для всех } i \neq j$$

Результат. На основе полученного графа строится матрица смежности $W = (w_{ij})$.

Ненормированный лапласиан графа

Матрицы графа.

- Матрица смежности: $W = (w_{ij})$
- Матрица степеней:

$$D = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_{j=1}^n w_{ij}$$

Определение.

$$L := D - W$$

называется **ненормированным лапласианом** графа.

Свойства ненормированного лапласиана


- L — симметричная и неотрицательно определённая матрица
- $$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2, \quad f \in \mathbb{R}^n$$
- Наименьшее собственное значение - 0, соответствующий собственный вектор — константный вектор $\mathbb{1}$.
- L имеет n неотрицательных собственных значений: $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$.

Теорема.


Пусть G - неориентированный граф с неотрицательными весами рёбер. Тогда число компонент связности в графе равно кратности собственного значения 0 его лапласиана L . Собственное подпространство, соответствующее собственному значению 0, порождается **индикаторными векторами этих компонент**.

Демонстрация собственных векторов лапласиана


Histogram of the sample




Eigenvalues




Eigenvector 1




Eigenvector 2




Eigenvector 3




Eigenvector 4




Eigenvector 5



Eigenvalues




Eigenvector 1




Eigenvector 2




Eigenvector 3



Eigenvector 4



Eigenvector 5



Кластеризация как разбиение графа

Интуиция кластеризации.

- Точки внутри одного кластера должны быть похожи
- Точки из разных кластеров — непохожи

Графовое представление данных.

- Вершины — объекты данных
- Веса рёбер w_{ij} — мера сходства

Задача. Найти разбиение графа на группы так, чтобы

- рёбра между группами имели малый вес,
- рёбра внутри групп — большой вес.

Подход. Рассматривать кластеризацию как задачу разбиения графа.

Минимальный разрез (mincut)

Обозначения. Для $A, B \subset V$ определим

$$W(A, B) := \sum_{i \in A} \sum_{j \in B} w_{ij}.$$

Разбиение на k кластеров. Пусть $V = A_1 \cup \dots \cup A_k$.

Определение разреза.

$$\text{cut}(A_1, \dots, A_k) := \frac{1}{2} \sum_{i=1}^k W(A_i, \bar{A}_i).$$

Идея mincut. Найти разбиение, минимизирующее суммарный вес рёбер между различными кластерами.

Проблема. На практике mincut часто отделяет одну вершину от остального графа, что не соответствует интуиции кластеризации.

Балансировка кластеров: RatioCut

Причина проблемы `mincut`.

- Размер кластеров никак не учитывается
- Малые множества оказываются выгодными

Идея. Явно требовать, чтобы кластеры были достаточно большими.

Определение RatioCut.

Для разбиения $V = A_1 \cup \dots \cup A_k$:

$$\text{RatioCut}(A_1, \dots, A_k) := \sum_{i=1}^k \frac{\text{cut}(A_i, \bar{A}_i)}{|A_i|}.$$

Интуиция.

- Малые кластеры сильно штрафуются
- Предпочтение отдаётся сбалансированным разбиениям

Минимизация RatioCut: переход к вектору f (случай $k = 2$)

Задача. Пусть $A \subset V$, $\bar{A} = V \setminus A$.

$$\text{RatioCut}(A, \bar{A}) := \text{cut}(A, \bar{A}) \left(\frac{1}{|A|} + \frac{1}{|\bar{A}|} \right).$$

Дискретный вектор, кодирующий разбиение. Определим $f \in \mathbb{R}^n$:

$$f_i = \begin{cases} \sqrt{\frac{|\bar{A}|}{|A|}}, & i \in A, \\ -\sqrt{\frac{|A|}{|\bar{A}|}}, & i \in \bar{A}. \end{cases}$$

Свойства f .

$$f \perp 1, \quad \|f\| = \sqrt{n}.$$

Идея. Минимизацию RatioCut по множествам A можно переписать как минимизацию квадратичной формы $f^\top L f$ по таким дискретным f .

Связь $f^\top Lf$ и RatioCut: идея доказательства

Напоминание. Для любого $f \in \mathbb{R}^n$:

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij}(f_i - f_j)^2.$$

Шаг 1. Внутрикластерные рёбра. Если $i, j \in A$ или $i, j \in \bar{A}$, то

$$f_i = f_j \quad \Rightarrow \quad (f_i - f_j)^2 = 0.$$

Следствие. Рёбра внутри кластеров не дают вклада в $f^\top Lf$.

Шаг 2. Межкластерные рёбра. Ненулевой вклад дают только рёбра, соединяющие A и \bar{A} .

Связь $f^\top Lf$ и RatioCut: вычисление

Разность значений на разрезе. Для $i \in A, j \in \bar{A}$:

$$f_i - f_j = \sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} = \frac{n}{\sqrt{|A||\bar{A}|}} \implies (f_i - f_j)^2 = \frac{n^2}{|A||\bar{A}|}.$$

Суммирование по рёбрам разреза. Так как

$$\sum_{i \in A, j \in \bar{A}} w_{ij} = \text{cut}(A, \bar{A}),$$

получаем

$$f^\top Lf = \text{cut}(A, \bar{A}) \cdot \frac{n^2}{|A||\bar{A}|}.$$

Следовательно,

$$f^\top Lf = n \cdot \text{RatioCut}(A, \bar{A}).$$

От дискретной задачи к спектральной релаксации ($k = 2$)

Эквивалентная дискретная оптимизация.

$$\min_{A \subset V} \text{RatioCut}(A, \bar{A}) \iff \min_f f^\top L f$$

при ограничениях

$$f \perp 1, \quad \|f\| = \sqrt{n}, \quad f_i \in \{\alpha, -\beta\}.$$

Это дискретная (комбинаторная) задача, в общем случае NP-трудная.

Спектральная релаксация.

Снимаем дискретность и разрешаем $f \in \mathbb{R}^n$:

$$\min_{f \perp 1, \|f\|=\sqrt{n}} f^\top L f.$$

Решение. (Rayleigh-Ritz theorem) Минимум достигается на собственном векторе, соответствующем второму наименьшему собственному значению L .

Возврат к дискретному разбиению

Проблема. Вектор f принимает непрерывные значения, а кластеризация требует дискретного разбиения вершин.

Интуиция. Компоненты f близки внутри кластера и существенно различаются между кластерами.

Решение (приводит к ответу).

Используем k-means для разбиения элементов вектора f на два кластера.

Минимизация RatioCut при $k > 2$

Постановка задачи. Пусть $V = A_1 \cup \dots \cup A_k$ — разбиение вершин графа на k кластеров.

$$\text{RatioCut}(A_1, \dots, A_k) = \sum_{i=1}^k \frac{\text{cut}(A_i, \bar{A}_i)}{|A_i|}.$$

Индикаторная матрица. Разбиение кодируется матрицей

$$H = (h_1, \dots, h_k) \in \mathbb{R}^{n \times k},$$

где каждый столбец h_i — нормированный индикатор кластера A_i .

Дискретная оптимизация. Минимизация RatioCut эквивалентна задаче

$$\min_H \text{Tr}(H^\top L H)$$

при ограничениях:

$$H^\top H = I, \quad H_{ji} \in \left\{ 0, \frac{1}{\sqrt{|A_i|}} \right\}, \quad \text{в каждой строке } H \text{ ровно один ненулевой элемент.}$$

Спектральная релаксация и алгоритм ($k > 2$)

Проблема. Эта задача является комбинаторной и NP-трудной.

Спектральная релаксация.

Снимаем дискретные ограничения и решаем

$$\min_{H \in \mathbb{R}^{n \times k}} \text{Tr}(H^\top L H), \quad \text{при } H^\top H = I.$$

Решение. (Rayleigh-Ritz theorem) Оптимальное H задаётся k собственными векторами лапласиана L , соответствующими наименьшим собственным значениям.

Спектральное вложение.

- Каждой вершине i сопоставляется строка $H_{i \cdot} \in \mathbb{R}^k$
- Вершины одного кластера имеют близкие строки

Возврат к дискретности (ответ).

Кластеризация строк матрицы H (например, методом k -средних) даёт итоговое разбиение графа.

Algorithm 1 Спектральная кластеризация (ненормированный лапласиан)

Require: Данные x_1, \dots, x_n , число кластеров k , граф сходства W

Ensure: Разбиение вершин на k кластеров

- 1: Построить матрицу степеней D , где $D_{ii} = \sum_{j=1}^n w_{ij}$
 - 2: Построить лапласиан $L = D - W$
 - 3: Найти k собственных векторов u_1, \dots, u_k матрицы L , соответствующих наименьшим собственным значениям
 - 4: Сформировать матрицу $U = (u_1, \dots, u_k) \in \mathbb{R}^{n \times k}$
 - 5: Применить алгоритм k -средних к строкам матрицы U
 - 6: **return** Кластерная принадлежность вершин
-